

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3074 – Minera de Datos

Sección 20



Laboratorio 9.

Redes Neuronales Artificiales (RNA)

Diego André Rosales Valenzuela – 23258

Erick Antonio Guerra Illescas – 23208

Diego José López Campos - 23242

GUATEMALA, 10 de mayo de 2026

1. Resumen Ejecutivo

SmartStay Advisors opera como intermediario entre clientes corporativos y particulares que buscan propiedades en Airbnb, optimizando precio, calidad y disponibilidad. Para fortalecer su capacidad de asesoramiento, la empresa solicitó el desarrollo de modelos de inteligencia artificial capaces de clasificar propiedades según su rango de precio y predecir el precio numérico de un listing dado sus características.

A lo largo de siete entregas, el equipo de consultoría exploró, preparó y modeló un conjunto de datos de 75,531 propiedades Airbnb utilizando siete familias de algoritmos: Árboles de Decisión, Random Forest, Naive Bayes, K-Nearest Neighbors, Regresión Logística, Máquinas de Soporte Vectorial y Redes Neuronales Artificiales. Todos los modelos fueron evaluados bajo las mismas condiciones de datos para garantizar comparaciones válidas.

Hallazgo principal: Las Redes Neuronales Artificiales superan a todos los algoritmos evaluados tanto en clasificación ($F1\text{-macro} = 0.7375$) como en predicción de precio ($RMSE = \$444.92$, $R^2 = 0.733$), con un nivel de sobreajuste bajo y un tiempo de entrenamiento operacionalmente aceptable.

2. Descripción del Problema y del Conjunto de Datos

2.1 Contexto de Negocio

SmartStay Advisors requiere dos capacidades analíticas concretas:

- **Clasificación de precio:** Categorizar automáticamente una propiedad como barata, media o cara, según los percentiles del mercado. Esto permite orientar al cliente corporativo hacia el segmento que corresponde a su presupuesto sin necesidad de revisar manualmente cada listing.
- **Predicción de precio:** Estimar el precio numérico esperado de una propiedad a partir de sus características. Esto es útil para identificar propiedades sub-valuadas (oportunidades) y para validar que el precio publicado es competitivo.

2.2 Conjunto de Datos

El análisis se basó en el dataset `listings.RData`, que contiene información detallada de propiedades Airbnb:

Característica	Valor
Registros originales	171,748
Registros tras filtro de precio ($>\$0$ y $\leq P99 = \$20,000$)	75,531
Variables predictoras utilizadas	21 (15 numéricas, 6 categóricas)
Variable respuesta (regresión)	<code>price_num</code> — precio numérico en USD
Variable respuesta (clasificación)	Categoría de precio: barata / media / cara

Variables numéricas: accommodates, bathrooms, bedrooms, beds, minimum_nights, maximum_nights, availability_365, number_of_reviews, reviews_per_month, review_scores_rating, host_response_rate, host_acceptance_rate, calculated_host_listings_count, latitude y longitude.

Variables categóricas: room_type, property_type, neighbourhood_cleansed, host_is_superhost, host_identity_verified e instant_bookable.

2.3 Segmentación de Datos

Para garantizar comparabilidad entre todas las entregas, se utilizó una única partición train/test, mantenida constante en todos los experimentos:

- **Entrenamiento:** 60,424 registros (80%).
- **Prueba:** 15,107 registros (20%).
- **Estratificación:** por deciles de precio logarítmico (random_state = 42).

2.4 Definición de Categorías de Precio

Los umbrales de clasificación se derivaron exclusivamente del conjunto de entrenamiento para evitar fuga de información:

- **Barata:** precio $\leq$ \$141 (percentil 33 del entrenamiento).
- **Media:** \$141 < precio $\leq$ \$260 (percentil 66 del entrenamiento).
- **Cara:** precio > \$260.

La distribución resultante es aproximadamente balanceada en ambos conjuntos (~33% por clase), lo que hace que el F1-macro sea la métrica principal de evaluación.

3. Análisis Exploratorio de Datos

El análisis exploratorio reveló las siguientes características estructurales del dataset que condicionaron las decisiones de modelado:

Distribución del precio: El precio de las propiedades sigue una distribución fuertemente sesgada a la derecha, con la mayoría de listings concentrados entre \$50 y \$300, pero con valores extremos que superan los \$10,000. Esto motivó el filtro al percentil 99 y explica el alto RMSE de todos los modelos de regresión: los outliers de precio son difíciles de predecir con precisión.

Variables más informativas: La capacidad (accommodates), el número de habitaciones (bedrooms) y el tipo de habitación (room_type) presentaron las correlaciones más altas con el precio. Las propiedades de tipo "Entire home/apt" son consistentemente más caras que las habitaciones privadas o compartidas. El vecindario (neighbourhood_cleansed) también es un predictor fuerte: zonas turísticas de alta demanda concentran precios en la categoría cara.

Valores faltantes: Varias variables numéricas (especialmente métricas de reseñas y tasas de respuesta del host) presentaban valores nulos. Se aplicó imputación por mediana para variables numéricas y por moda para categóricas, manteniendo la misma estrategia en todas las entregas.

Necesidad de preprocesamiento: La escala heterogénea de las variables numéricas y el alto número de categorías únicas en `neighbourhood_cleansed` y `property_type` requirieron estandarización (`StandardScaler`) y codificación one-hot (`OneHotEncoder`) en un pipeline consistente aplicado a todos los modelos.

4. Modelos de Clasificación de Precio

Se evaluaron siete familias de algoritmos para la tarea de clasificar propiedades en las categorías barata, media y cara. La métrica principal es el F1-macro, que pondera igualmente las tres clases.

4.1 Resultados Comparativos

Modelo	Accuracy	F1 Macro	Tiempo (s)
Naive Bayes	0.4324	0.3568	0.43
Árbol de Decisión	0.6667	0.6644	0.51
KNN (k óptimo)	0.6675	0.6668	3.57
Regresión Logística	0.6815	0.6792	4.20
Random Forest	0.7096	0.7068	1.26
SVM (RBF, C óptimo)	0.7175	0.7177	15.26
RNA ReLU (100-50-25)	0.7367	0.7375	28.70

4.2 Análisis por Algoritmo

Naive Bayes resultó el peor clasificador con $F1 = 0.3568$. Su asunción de independencia condicional entre variables es violada en este dataset, donde características como `accommodates` y `bedrooms` están fuertemente correlacionadas. Queda descartado para este problema.

Árbol de Decisión con `max_depth = 7` logra $F1 = 0.6644$ en 0.51 segundos. Es el modelo más interpretable: sus reglas de decisión pueden explicarse a los directivos de SmartStay sin conocimiento técnico. Sin embargo, su precisión es limitada y tiene tendencia al sobreajuste si no se controla la profundidad.

KNN ($k = 5$, métrica Manhattan) alcanza $F1 = 0.6668$. Es competitivo con el Árbol pero requiere almacenar todos los datos de entrenamiento para la predicción, lo que lo hace poco escalable en producción.

Regresión Logística fue entrenada para clasificación binaria (cara vs no cara) y muestra $F1 = 0.6792$ en la aproximación de 3 clases. Es un modelo lineal que no captura interacciones no lineales entre variables, pero ofrece coeficientes interpretables.

Random Forest (ensamble de árboles) eleva el F1 a 0.7068 con un tiempo de entrenamiento de apenas 1.26 segundos. La agregación de múltiples árboles reduce la varianza y mejora la generalización. Es la mejor opción si el tiempo de entrenamiento es una restricción crítica.

SVM con kernel RBF logra $F1 = 0.7177$, superando al Random Forest. El kernel RBF transforma el espacio de características para encontrar hiperplanos de separación no lineales. Su principal desventaja es el tiempo: 15.26 segundos, mayor que Random Forest y comparable a la RNA.

RNA ReLU (100-50-25) alcanza el mejor F1-macro (0.7375) con tres capas ocultas de tamaño decreciente y activación ReLU. La arquitectura permite capturar relaciones no lineales complejas entre variables. El mecanismo de early stopping controló el sobreajuste durante el entrenamiento.

4.3 Patrones de Error

En todos los modelos, la categoría media presentó la mayor tasa de error, lo cual es esperable: sus límites (\$141–\$260) son fronteras difusas en una distribución continua de precios, y propiedades en los bordes del umbral son ambiguas por naturaleza. El error crítico para el negocio —confundir barata con cara— fue el menos frecuente en todos los modelos.

5. Modelos de Predicción de Precio

Se evaluaron seis familias de algoritmos para predecir el precio numérico de las propiedades. Las métricas principales son RMSE (penaliza errores grandes) y R^2 (varianza explicada).

5.1 Resultados Comparativos

Modelo	RMSE (USD)	MAE (USD)	R^2	Tiempo (s)
SVR (kernel polinomial)	768.11	169.79	0.205	25.51
Regresión Lineal	766.60	268.93	0.208	1.06
KNN Regresión	585.84	155.93	0.537	0.15
Árbol de Regresión	569.74	165.33	0.563	0.52
Random Forest Reg.	517.78	141.94	0.639	7.27
RNA ReLU (100-50-25)	444.92	146.89	0.733	37.60

5.2 Análisis por Algoritmo

Regresión Lineal obtiene $R^2 = 0.208$, lo que significa que el modelo solo explica el 20.8% de la varianza del precio. El precio de las propiedades Airbnb depende de interacciones no lineales que la regresión lineal no puede capturar. Sin embargo, su coeficiente de regresión por variable sigue siendo útil para comunicar qué factores incrementan o disminuyen el precio de forma marginal.

SVR tampoco mejora sobre la regresión lineal ($R^2 = 0.205$), a pesar de ser un algoritmo más complejo y tardar 25.51 segundos. El kernel polinomial no encontró una representación eficiente del espacio de características para este problema.

KNN Regresión muestra $R^2 = 0.537$ con un tiempo de predicción casi instantáneo, pero sufre sobreajuste severo: RMSE de \$1.66 en entrenamiento vs \$585.84 en prueba (gap = \$584). Esto indica que memoriza los datos de entrenamiento en lugar de generalizar.

Árbol de Regresión con $\text{max_depth} = 7$ mejora a $R^2 = 0.563$. Al igual que en clasificación, es el modelo más interpretable pero con capacidad predictiva limitada.

Random Forest Regresión sube a $R^2 = 0.639$ en 7.27 segundos. La reducción del sesgo mediante el ensamble de árboles es notable, aunque el gap train-test de \$111 indica sobreajuste moderado.

RNA ReLU (100-50-25) lidera con $R^2 = 0.733$ y $\text{RMSE} = \$444.92$. Explica el 73.3% de la varianza del precio, lo que representa una mejora de ~9 puntos porcentuales sobre Random Forest. Con un MAE de \$146.89, el precio predicho se aleja en promedio \$147 del precio real, un margen razonable dado el rango del dataset (\$0–\$20,000).

6. Análisis de Sobreajuste

El sobreajuste es un criterio de calidad adicional a la precisión: un modelo que funciona muy bien en entrenamiento pero falla en datos nuevos no es confiable para producción.

6.1 Sobreajuste en Modelos de Regresión

Modelo	RMSE Train	RMSE Test	Gap	Diagnóstico
KNN	\$1.66	\$585.84	\$584	Sobreajuste severo
Random Forest	\$406.82	\$517.78	\$111	Sobreajuste moderado
Árbol de Regresión	\$477.65	\$569.74	\$92	Sobreajuste moderado
RNA ReLU	\$400.35	\$444.92	\$45	Bajo
Regresión Lineal	\$784.50	\$766.60	–\$18	Sub-ajuste
SVR	\$787.31	\$768.11	–\$19	Sub-ajuste

La RNA presenta el menor gap de sobreajuste entre los modelos que generalizan bien (\$45), gracias al mecanismo de early stopping que detuvo el entrenamiento en época 63 cuando la pérdida en validación interna dejó de mejorar. KNN queda completamente descartado por su sobreajuste catastrófico a pesar de su bajo MAE en entrenamiento.

6.2 Sobreajuste en Modelos de Clasificación

Los dos modelos RNA de clasificación presentan un gap train-test de ~ 8 puntos porcentuales en F1-macro (Train F1 ≈ 0.819 , Test F1 ≈ 0.737). Este nivel es **moderado pero aceptable** dado que el dataset tiene una variabilidad de precio intrínsecamente alta. El early stopping con `n_iter_no_change = 20` fue efectivo como regularización implícita.

Para los modelos clásicos de clasificación no se dispone de métricas de entrenamiento comparables, pero dado el tamaño del dataset (60,424 registros de entrenamiento) y los hiperparámetros usados, se espera sobreajuste bajo en Random Forest y SVM.

7. Conclusiones y Recomendaciones

7.1 Mejor Modelo para Clasificación de Precio

Recomendación: RNA_RelU_100_50_25

Con F1-macro = 0.7375, la RNA supera a todos los algoritmos evaluados. Clasifica correctamente el 73.7% de las propiedades en su categoría correcta, con errores concentrados en la categoría media (la más ambigua por definición). El sobreajuste es moderado y controlado.

Como alternativa operativa, SVM (F1 = 0.7177) ofrece precisión cercana con un tiempo de entrenamiento menor. Si el sistema de SmartStay requiere re-entrenamientos frecuentes con recursos limitados, SVM es una opción viable.

7.2 Mejor Modelo para Predicción de Precio

Recomendación: RNA_Reg_ReLU_100_50_25

Con RMSE = \$444.92 y $R^2 = 0.733$, la RNA supera a todos los modelos de regresión evaluados. Explica el 73.3% de la varianza del precio y presenta el menor gap de sobreajuste (\$45). Para SmartStay Advisors, esto significa que el sistema puede estimar el precio de una propiedad con un margen de error promedio de \$147, lo cual es suficientemente preciso para orientar decisiones de negociación y asesoramiento de presupuesto.

Como alternativa rápida, Random Forest (RMSE = \$517.78, $R^2 = 0.639$) entrena en 7.27 segundos y sería adecuado si se requiere un modelo de respaldo con menor costo computacional.

7.3 Modelos Descartados para Producción

- **Naive Bayes:** F1 = 0.3568 — inaceptable para clasificación de 3 clases con variables correlacionadas.
- **KNN Regresión:** Sobreajuste catastrófico (gap RMSE = \$584) — no generaliza.
- **Regresión Lineal y SVR:** Sub-ajuste estructural — no capturan la no-linealidad del precio Airbnb.

Link de repositorio:

<https://github.com/jcdiegolopez/MD-LAB09.git>